

Universidade Estadual do Ceará
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA
COMPUTAÇÃO

Relatório Técnico

Aluno: Antônio Sérgio de Sousa Vieira
Professor orientador: Dr. Joaquim Celestino Júnior

Fevereiro
2025

Universidade Estadual do Ceará
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA
COMPUTAÇÃO

Relatório Técnico

Relatório Técnico de Pesquisa e Desenvolvimento
sobre técnicas para descarregamento de tarefas em
ambientes veiculares.

Aluno: Antônio Sérgio de Sousa Vieira

Professor orientador: Dr. Joaquim Celestino Júnior

Fevereiro
2025

Conteúdo

1	Resumo	1
2	Apresentação	2
2.1	Modelo de Sistema	3
3	Descrição de Atividades	4
4	Solução Proposta	4
4.1	Implementação do Algoritmo FOFF	5
5	Análise dos Resultados	7
6	Trabalhos Futuros	10
	Bibliografia	11

1 Resumo

A crescente demanda por processamento de dados em redes veiculares autônomas pode exceder a capacidade computacional das Unidades Embarcadas (OBUI). O Vehicle Edge Computing (VEC) possibilita o processamento de grandes volumes de dados, mas enfrenta desafios críticos relacionados à latência e ao consumo energético. Este trabalho apresenta o método inovador **Fuzzy Offloading (FOFF)**, que equilibra critérios conflitantes para otimizar tanto o consumo de energia quanto a latência no offloading de tarefas. Os experimentos demonstram que, em comparação com estratégias gananciosas de offloading, o FOFF pode reduzir o consumo de energia em até 96,85%.

2 Apresentação

A popularização e a redução dos custos de diversas tecnologias de comunicação e dos dispositivos com alta capacidade computacional impulsionaram o interesse pelo desenvolvimento de veículos autônomos. No entanto, a criação de sistemas para esse fim apresenta desafios complexos.

Entre os principais problemas, destaca-se a alta demanda por processamento com tempos de resposta mínimos, sem abrir mão da economia energética. Dessa forma, diversas propostas têm sido desenvolvidas, especialmente aquelas que utilizam dispositivos com maior robustez computacional, fortalecendo o papel da Computação de Borda Veicular (VEC) na implementação de ambientes autônomos e conectados.

A decisão sobre quando e onde descarregar um grande volume de dados é crucial para atender às necessidades computacionais dos veículos autônomos. Esse processo, denominado descarregamento de tarefas, pode ser realizado de duas maneiras: descarregamento binário – onde se decide entre processar localmente ou descarregar completamente –, ou descarregamento parcial – que permite dividir a tarefa e processá-la simultaneamente localmente e na borda. Inicialmente, nossa pesquisa focou apenas no descarregamento binário.

Várias abordagens foram propostas para reduzir o tempo de processamento e o consumo de energia em ambientes veiculares, utilizando algoritmos gananciosos, metaheurísticas e aprendizado por reforço. Entretanto, acreditamos que a aplicação da lógica fuzzy pode oferecer uma solução inovadora para ambientes altamente dinâmicos.

Este trabalho propõe um método eficiente para determinar a alternativa ideal para processamento, levando em conta o custo temporal do offloading e o consumo energético na borda. Considera-se, portanto, se é mais vantajoso processar localmente ou descarregar os dados, considerando fatores como tempo de upload, espera em filas, processamento e recuperação dos dados.

Para isso, empregamos a técnica Fuzzy TOPSIS (Técnica para Ordem de Preferência por Similaridade com a Solução Ideal), que gera um ranking dos melhores dispositivos para a decisão de offloading em cenários multicritério.

Nossos experimentos, envolvendo um veículo interagindo com cinco dispositivos de borda via comunicação 5G, demonstram que o FOFF integra latência, consumo energético e disponibilidade computacional de forma eficaz, adaptando-se a diferentes cenários operacionais.

As principais contribuições deste trabalho são:

1. Desenvolvimento de uma solução inovadora para descarregamento de tarefas baseada no Fuzzy TOPSIS, visando equilibrar consumo energético e latência.

2. Proposição de um método alternativo para converter valores exatos em números fuzzy triangulares (*WeightedMapping*), aumentando a sensibilidade do ranking aos pesos dos critérios.
3. Demonstração de que o FOFF pode reduzir o consumo de energia em aproximadamente 95,28% a 96,85% quando comparado com abordagens gananciosas.
4. Integração de fatores como latência, consumo energético e capacidade computacional na tomada de decisão, proporcionando uma solução robusta para cenários veiculares.

2.1 Modelo de Sistema

Cada tarefa é representada por $T_i = (d_i, c_i)$, onde d_i corresponde ao tamanho dos dados e c_i à densidade computacional. A fração de offloading é denotada por $\alpha_i \in [0, 1]$. As latências de computação local e remota são definidas respectivamente como:

$$L_i^l = \frac{(1 - \alpha_i)c_i d_i}{f_i^l}, \quad (1)$$

$$L_i^e = \frac{\alpha_i c_i d_i}{f_i^e}. \quad (2)$$

A latência total da tarefa, que inclui transmissão, recepção e espera na fila, é calculada por:

$$L_i^t = L_i^l + L_i^e + L_i^u + L_i^d + Q_t. \quad (3)$$

O consumo energético total é dado por:

$$E_i^t = E_i^l + E_i^e + E_i^d + E_i^u. \quad (4)$$

Nosso objetivo é minimizar a soma da latência e do consumo energético:

$$\min [L_i^t + E_i^t]. \quad (5)$$

3 Descrição de Atividades

Inicialmente, foi desenvolvido um simulador de eventos em Python para avaliar o desempenho do FOFF. Esse simulador permite configurar diferentes cenários de rede e capacidades computacionais dos dispositivos de borda. As principais etapas do desenvolvimento foram:

1. **Desenvolvimento do Simulador:** Implementação de um simulador para avaliar o desempenho do FOFF em cenários veiculares.
2. **Modelagem dos Dispositivos de Borda:** Cada dispositivo foi caracterizado por atributos como capacidade computacional, consumo energético e tempo de fila.
3. **Geração de Tarefas:** Foram geradas tarefas com variados tamanhos de dados e densidades computacionais, simulando um ambiente veicular realista.
4. **Implementação do Algoritmo FOFF:** O algoritmo FOFF foi implementado para classificar e selecionar o dispositivo de borda mais adequado para cada tarefa.
5. **Execução das Simulações:** Diversos cenários foram simulados para avaliar o desempenho do FOFF em termos de consumo energético e latência.

Os resultados indicaram que o FOFF reduz significativamente o consumo energético em comparação com outras abordagens, mantendo tempos de resposta adequados.

4 Solução Proposta

O método **FOFF** utiliza o *Fuzzy TOPSIS* para classificar os dispositivos disponíveis e selecionar o mais adequado para processar cada tarefa, considerando critérios como capacidade computacional, tempo de fila e consumo energético. A metodologia contempla duas abordagens para converter valores numéricos em números fuzzy triangulares: *DirectMapping* e *WeightedMapping*. Os experimentos demonstraram que o *WeightedMapping* confere maior sensibilidade às preferências dos critérios, resultando em decisões de offloading mais precisas.

Para implementar o FOFF, foram seguidos os seguintes passos:

1. **Definição dos Critérios e Pesos:** Identificação dos critérios relevantes para a decisão de offloading e atribuição de pesos conforme sua importância.
2. **Conversão para TFNs:** Os valores dos critérios são convertidos em números fuzzy triangulares utilizando as abordagens *DirectMapping* e *WeightedMapping*.
3. **Construção da Matriz de Decisão Fuzzy:** Montagem de uma matriz em que cada elemento representa um TFN associado a um critério de cada dispositivo.
4. **Normalização da Matriz:** Normalização da matriz para que os critérios fiquem na mesma escala.
5. **Cálculo das Distâncias Fuzzy:** Cálculo das distâncias dos dispositivos em relação às soluções ideais positiva e negativa.
6. **Classificação dos Dispositivos:** Classificação dos dispositivos com base nas distâncias obtidas, selecionando-se aquele com a menor distância ao ideal positivo e a maior ao negativo.
7. **Seleção do Dispositivo:** Escolha do dispositivo com a melhor classificação para o processamento da tarefa.

Esses passos asseguram que o FOFF possa tomar decisões de offloading de forma eficiente e sensível às preferências definidas.

4.1 Implementação do Algoritmo FOFF

A implementação do FOFF foi realizada em Python, utilizando bibliotecas como NumPy e SciPy para operações matemáticas e de otimização. A seguir, um trecho do código que realiza a classificação dos dispositivos de borda utilizando Fuzzy TOPSIS:

```
def fuzzy_topsis(D_tilde, W_tilde, criteria_types):
    R_tilde = np.zeros_like(D_tilde, dtype=float)
    for j in range(D_tilde.shape[1]):
        if criteria_types[j] == Criteria.BENEFIT:
            R_tilde[:, j, :] = normalize_by_benefit(
                D_tilde[:, [j], :])[:, 0, :]
        elif criteria_types[j] == Criteria.COST:
            R_tilde[:, j, :] = normalize_by_cost(
```



```

        D_tilde[:, [j], :])[:, 0, :]
    else:
        raise ValueError(f"Invalid criteria type for
                           criterion {j}: {criteria_types[j]}")
    V_tilde = R_tilde * W_tilde
    A_plus = positive_ideal_solution(V_tilde, criteria_types)
    A_minus = negative_ideal_solution(V_tilde, criteria_types)
    D_plus, D_minus = calculate_distances(V_tilde, A_plus, A_minus)
    CCI = calculate_closeness_coefficient(D_plus, D_minus)
    server_names = [f"{i}" for i in range(len(D_tilde))]
    results = [[server_names[i], CCI[i]] for i in range(len(server_names))]
    ranked_alternatives = sorted(results, key=lambda item: item[1], reverse=True)
    return ranked_alternatives

```

O trecho acima ilustra a implementação do Fuzzy TOPSIS para classificar os dispositivos de borda com base em critérios como capacidade computacional, tempo de fila e consumo energético. A partir da normalização e ponderação da matriz de decisão, são calculadas as distâncias em relação às soluções ideais, que, por sua vez, geram os coeficientes de proximidade utilizados na classificação final.

5 Análise dos Resultados

As simulações foram conduzidas em cenários desafiadores e equilibrados, considerando dispositivos de borda com diferentes capacidades computacionais e coeficientes de consumo energético.

No cenário desafiador (Tabela ??), os resultados demonstram que o FOFF atingiu um consumo médio de energia de $13.593,08 \text{ J} \pm 0,0$, processando 100 tarefas em 1000 segundos. Em comparação, o GCF e o GTT registraram consumos de $432.607,10 \text{ J} \pm 0,0$ e $288.344,35 \text{ J} \pm 0,0$, respectivamente, representando reduções de 96,85% e 95,28%. Já o ROFF, com $173.263,01 \text{ J} \pm 522,66$, mostra uma redução de 92,15% em comparação ao FOFF.

A Figura 1 ilustra o consumo total de energia no cenário desafiador.




Figura 1: Consumo total de energia no cenário desafiador.

Em relação ao tempo de processamento, no cenário desafiador o FOFF registrou um tempo total de $359,96 \text{ s} \pm 0,00$. Embora fique atrás do GTT ($56,94 \text{ s} \pm 0,00$) e próximo ao GCF ($357,98 \text{ s} \pm 0,00$), essa abordagem evita servidores energeticamente ineficientes. O ROFF, apesar de apresentar $308,19 \text{ s} \pm 2,85$, tem um consumo energético significativamente maior. A Figura 2 apresenta a comparação do tempo de processamento no cenário desafiador.

No cenário equilibrado (Tabela ??), o FOFF apresentou um consumo médio de $7.874,34 \text{ J} \pm 0,0$, desempenho semelhante ao GTT e reduziu o consumo em 86,20% se comparado ao GCF, e 70,03% em relação ao ROFF. Além disso, sua latência total foi de $52,13 \text{ s} \pm 0,00$, equiparando-se ao GTT e superando o ROFF e o GCF. A Figura 3 ilustra a latência total para processar todas as tarefas no cenário equilibrado.

Outro ponto importante é a eficácia do método *WeightedMapping*, que melhora a conversão dos valores exatos em números fuzzy triangulares, tornando o ranking mais sensível aos pesos atribuídos. Essa flexibilidade permite




Figura 2: Comparação do tempo total de processamento no cenário desafiador.




Figura 3: Latência total no cenário equilibrado.

que o FOFF seja ajustado conforme as prioridades – seja para otimização energética ou redução de latência.

Resumidamente, os principais resultados foram:

- **Cenário Desafiador:** FOFF reduziu o consumo energético em até 96,85% comparado ao GCF e 95,28% em relação ao GTT.
- **Cenário Equilibrado:** Desempenho energético semelhante ao GTT, com redução de 86,20% do consumo comparado ao GCF.
- **Latência:** FOFF apresentou tempos de resposta aceitáveis, equilibrando eficientemente o trade-off entre latência e consumo energético.

6 Trabalhos Futuros

O FOFF demonstrou ser uma solução eficiente para o offloading de tarefas em redes veiculares com tecnologia 5G-VEC, reduzindo significativamente o consumo energético sem comprometer a latência. A evolução na conversão fuzzy via *WeightedMapping* aprimorou a sensibilidade da decisão. Trabalhos futuros poderão explorar a adaptação da solução a cenários mais dinâmicos, considerando a velocidade dos veículos e variações na conectividade, além da incorporação de aprendizado por reforço para decisões mais adaptativas.

Bibliografia

PAVLACKA, O.; TALAŠOVÁ, J. The fuzzy weighted average operation in decision making models. In: Proceedings of the 24th International Conference Mathematical Methods in Economics, 13th-15th September, 2006. p. 419-426.

KAUFMANN, A.; GUPTA, M. M. Introduction to Fuzzy Arithmetic: Theory and Applications. New York: Van Nostrand Reinhold, 1991.

ZIMMERMANN, H.-J. Fuzzy set theory—and its applications. Springer Science & Business Media, 2011.

FRIIS, H. T. A note on a simple transmission formula. Proceedings of the IRE, v. 34, n. 5, p. 254-256, 1946.

SU, M.; WANG, G.; CHEN, J. Efficient task offloading with swarm intelligence evolution for edge-cloud collaboration in vehicular edge computing. Software: Practice and Experience, v. 54, n. 10, p. 1888-1915, 2024.

YANG, J.; CHEN, Y.; LIN, Z.; TIAN, D.; CHEN, P. Distributed computation offloading in autonomous driving vehicular networks: a stochastic geometry approach. IEEE Transactions on Intelligent Vehicles, 2023.

XU, X.; YANG, C.; BILAL, M.; LI, W.; WANG, H. Computation offloading for energy and delay trade-offs with traffic flow prediction in edge computing-enabled iov. IEEE Transactions on Intelligent Transportation Systems, v. 24, n. 12, p. 15613-15623, 2022.

SARIEDDINE, K.; ARTAIL, H.; SAFA, H. An opportunistic vehicle-based task assignment for IoT offloading. Computer Networks, v. 212, p. 109038, 2022.

WU, X.; DONG, S.; HU, J.; HUANG, Z. An efficient many-objective optimization algorithm for computation offloading in heterogeneous vehicular edge computing network. Simulation Modelling Practice and Theory, v. 131, p. 102870, 2024.

LU, L.; YU, J.; DU, H.; LI, X. A3C-based load-balancing solution for computation offloading in SDN-enabled vehicular edge computing networks. Peer-to-Peer Networking and Applications, v. 16, n. 2, p. 1242-1256, 2023.

KO, H.; KIM, J.; RYOO, D.; CHA, I.; PACK, S. A belief-based task offloading algorithm in vehicular edge computing. IEEE Transactions on Intelligent Transportation Systems, v. 24, n. 5, p. 5467-5476, 2023.

DE SOUZA, A. B.; REGO, P. A. L.; CARNEIRO, T.; ROCHA, P. H. G.; DE SOUZA, J. N. A context-oriented framework for computation offloading in vehicular edge computing using WAVE and 5G networks. Vehicular Communications, v. 32, p. 100389, 2021.

RAPPAPORT, T. S. Wireless communications: principles and practice. Cambridge University Press, 2024.

OUGHTON, E. J.; KATSAROS, K.; ENTEZAMI, F.; KALESKI, D.; CROWCROFT, J. An open-source techno-economic assessment framework for 5G deployment. *IEEE Access*, v. 7, p. 155930-155940, 2019.

DE SOUZA, A. B.; REGO, P. A. L.; DE SOUZA, J. N. A Context-Oriented Framework and Decision Algorithms for Computation Offloading in Vehicular Edge Computing. In: *Anais Estendidos do XL Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*, 2022. p. 153-160.

FOFANA, N.; LETAÏFA, A. B.; RACHEDI, A. Intelligent task offloading in vehicular networks: a deep reinforcement learning perspective. *IEEE Transactions on Vehicular Technology*, 2024.

ABUTHAHIR, S. S.; PETER, J. S. P. Tasks Offloading in Vehicular Edge Computing Network using Meta-Heuristic Algorithms-A Study of Selected Algorithms. In: *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, 2024. p. 1-10.

LIU, L.; CHEN, C.; PEI, Q.; MAHARJAN, S.; ZHANG, Y. Vehicular edge computing and networking: A survey. *Mobile networks and applications*, v. 26, p. 1145-1168, 2021.

KATARE, D.; PERINO, D.; NURMI, J.; WARNIER, M.; JANSSEN, M.; DING, A. Y. A survey on approximate edge AI for energy efficient autonomous driving services. *IEEE Communications Surveys & Tutorials*, 2023.

MARKO, N.; MÖHLMANN, E.; NIČKOVIĆ, D.; NIEHAUS, J.; PRILLER, P.; ROOKER, M. Challenges of engineering safe and secure highly automated vehicles. *arXiv preprint arXiv:2103.03544*, 2021.

DONG, S.; TANG, J.; ABBAS, K.; HOU, R.; KAMRUZZAMAN, J.; RUTKOWSKI, L.; BUYYA, R. Task offloading strategies for mobile edge computing: A survey. *Computer Networks*, p. 110791, 2024.

SUN, G.; WANG, Z.; SU, H.; YU, H.; LEI, B.; GUIZANI, M. Profit maximization of independent task offloading in MEC-enabled 5G internet of vehicles. *IEEE Transactions on Intelligent Transportation Systems*, 2024.

TANG, H. H.; AHMAD, N. S. Fuzzy logic approach for controlling uncertain and nonlinear systems: a comprehensive review of applications and advances. *Systems Science & Control Engineering*, v. 12, n. 1, p. 2394429, 2024.

KUMARI, N.; YADAV, A.; JANA, P. K. Task offloading in fog computing: A survey of algorithms and optimization techniques. *Computer Networks*, v. 214, p. 109137, 2022.

AGBESI, P. K.; RUFFINO, R.; HAKOVIRTA, M. The development of sustainable electric vehicle business ecosystems. *SN Business & Economics*, v. 3, n. 8, p. 143, 2023.

CHEN, C.-T. Extensions of the TOPSIS for group decision-making under fuzzy environment. *Fuzzy Sets and Systems*, v. 114, n. 1, p. 1-9, 2000.

BAGLOEE, S. A.; TAVANA, M.; ASADI, M.; OLIVER, T. Autonomous vehicles: challenges, opportunities, and future implications for transportation policies. *Journal of modern transportation*, v. 24, p. 284-303, 2016.

MIGLANI, A.; KUMAR, N. Deep learning models for traffic flow prediction in autonomous vehicles: A review, solutions, and challenges. *Vehicular Communications*, v. 20, p. 100184, 2019.

AZIMJONOV, J.; ÖZMEN, A. A real-time vehicle detection and a novel vehicle tracking systems for estimating and monitoring traffic flow on highways. *Advanced Engineering Informatics*, v. 50, p. 101393, 2021.

ALIYU, A.; ABDULLAH, A. H.; KAIWARTYA, O.; CAO, Y.; LLORET, J.; ASLAM, N.; JODA, U. M. Towards video streaming in IoT Environments: Vehicular communication perspective. *Computer Communications*, v. 118, p. 93-119, 2018.

DUAN, Y.; JIANG, C. Binary task offloading strategy for cloud robots using improved game theory in cloud-edge collaboration. *The Journal of Supercomputing*, v. 80, n. 10, p. 14752-14777